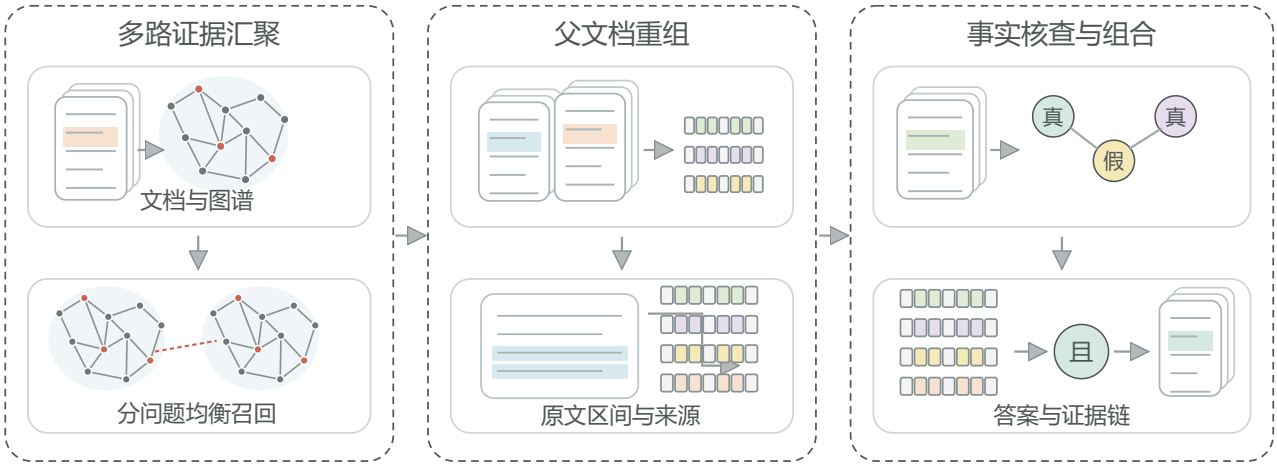
河南大学　观微算法队

人工智能算法竞赛技术报告

证据链重组
提升多跳问答质量

父文档融合与三值逻辑核验方法



86.00%
留出集完全匹配率

+ 31
相对基础方案提升百分点

609
真实新闻文档

参赛团队　观微算法队

团队成员　韩昌达　张中瑜　李嘉栋

所属学校　河南大学

提交日期　2026年10月15日

目录

摘要 3
一 引言 4
二 相关工作 5
三 问题设定 6
四 方法设计 7
4.1 多路召回与父文档融合 8
4.2 原子事实与三值逻辑 9
4.3 有限预算下的纠错 10
五 实验设置 11
5.1 数据集与证据角色 11
5.2 运行参数与对照方案 12
5.3 开发筛选与冻结流程 13
六 实验结果 14
6.1 整体性能 14
6.2 分题型表现 15
6.3 消融与错误取舍 16
6.4 真实证据链案例 17
七 工程实现与资源 18
7.1 模块协同与结果留存 18
7.2 显存与运行记录 19
八 结论 20
参考文献 21
附录甲 评估定义与逻辑规则 22
附录乙 复现材料与验证结果 23

摘要

多跳问答需要从不同文档中找齐事实，再判断它们是否共同支持一个结论。现有段落检索、图谱检索和生成后核验分别改善了相关性、关系发现或事实检查，却仍容易在原文截断、来源限定和否定组合之间留下衔接缺口。同题实验显示，单纯补检索在100道留出题上的完全匹配率为57.00%，而重组证据并配合结构化推理后，完整流程达到86.00%。

据此，我们提出观微证据链问答方法，将文档级融合、父上下文恢复与显式逻辑核验接成一条推理链。方法先按问题需求组织多路候选，再用相关性重排与原文区间合并恢复上下文，并把真假事实的判断与最终“是 / 否”的组合分开处理。实验围绕609篇新闻构建知识库，采用24题开发集、40题验证集和排除既往测试题的新100题留出集。最终方案确定后冻结源码与题目划分，并在同题候选、初始证据配对的条件下比较五种流程。

完整流程取得86.00%的完全匹配率和86.80%的词元重合分数，相对基础方案提高31个百分点；88道可回答题的完全匹配率为84.09%，40题验证集为87.50%。比较题由14.81%升至77.78%，时间题由40.00%升至80.00%，体现了证据组织对跨来源组合的帮助。项目交付包含真实模型响应、逐题评分、原文定位和源码快照，可直接用于运行演示与结果复核。

核心思路

先把问题拆成需要核对的事实，再把每条事实放回完整的报道语境，最后依据事实状态组合答案。这样，相关材料、可用证据和最终结论有了清楚的衔接。

关键词

多跳问答　检索增强生成　父文档融合　证据链　三值逻辑

一 引言

在609篇新闻构成的知识库中，我们抽取的100道留出题有27道比较题，基础流程只答对其中4道。对“两个来源是否表达同一件事”这样的提问，检索到同一主题并不够：报道对象、时间和归因只要有一处错位，几段看似相关的文字也无法给出正确关系。

我们把这类问题称为“证据衔接缺口”：材料已经进入候选集合，能够连成答案的事实却没有完整进入推理过程。缺口既可能来自片段截断，也可能来自重复片段挤占上下文，还可能来自把“题干命题为假”误判成“否定答案不成立”。

已有工作大致沿三条路线推进：稠密检索与多段融合改善候选文本获取，但不直接保证父文档语境完整[1–3]；图谱和交替检索推理加强实体关系与多步搜索，但仍需处理原文来源和问题限定之间的对齐[4–6]；纠错、验证链与自反思方法增加检查步骤，但事实判定与最终答案组合不一定显式分开[7–9]。三条路线提供了重要基础，也提示我们应把证据交接过程单独设计。

观微证据链以问题和原始文档为输入，先分解证据需求，再融合词项、图谱与向量候选；重排后按字符偏移展开父文档，生成短答案与来源事实。对于能解析为布尔关系的问题，核验器在看不到候选答案的条件下判断原子事实，程序再组合“且、或、非”得到结论；证据不足时，仅按缺失内容做一次受控修复。输出同时包含答案、引用和执行轨迹。

本项目的贡献集中在以下三个可交付部件：

- **父文档证据组织器**：多路文档融合、按子问题选证及原文区间恢复。
- **事实与答案解耦核验器**：来源限定命题、候选不可见核查及三值逻辑组合。
- **可复核实验工件**：固定划分、配对候选、来源偏移、真实响应与冻结快照。

二 相关工作

段落检索与生成融合。 稠密段落检索通过双编码器获取语义相关文本[1]，检索增强生成把外部索引接入语言模型[2]，多段融合生成则在解码时汇集多条段落的信息[3]。这些方法解决了“从哪里取材料”和“怎样读取多段文字”，本项目进一步处理“局部命中怎样恢复成可组合的父文档证据”。

图谱组织与多步搜索。 轻量图谱检索结合实体关系和向量表示[4]，全局图谱摘要通过社区结构汇聚文档信息[5]，交替检索推理让新推理步骤继续引导搜索[6]。它们分别扩展关系组织和搜索过程，本项目把这些能力接入原文层，并以来源、时间和精确偏移约束证据交接。

纠错与生成后核验。 纠错式检索根据证据质量选择后续动作[7]，验证链通过相对独立的检查问题修订回答[8]，自反思式检索学习何时检索以及怎样评价生成[9]。这条路线强调检查与反馈，本项目则把原子事实的真假判断交给核验步骤，把答案的逻辑组合交给程序。

最近邻方法的具体分工

轻量图谱检索是本项目直接复用的底座，我们保留其图向量召回，把新增工作放在父文档恢复与命题组合上。纠错式检索提供质量驱动路由的启发，我们在固定语料内按缺失事实补证，并保存每次修复的原文变化。

文献路线	已有机制	本项目的接续位置
段落检索与融合	相关文本获取及多段读取	父文档语境与子问题选证
图谱与多步搜索	关系结构及渐进式检索	来源限定与原文区间对齐
纠错与验证	质量判断及生成修订	事实判定与逻辑组合分离

三 问题设定

设想研究人员需要核对两篇报道：其中一篇说某球员伤后入选，另一篇说另一球员因伤退出。系统应分别找到这两条来源事实，再判断题目要求的对应关系，而不是仅因两篇都出现“伤病”就给出肯定答案。

为避免符号混用，以“问”表示输入问题，“文”表示可检索文档全集，“证”表示被选中的原文片段及来源，“答”表示最终短答案，“迹”表示检索、核查和修复记录。每条“证”都记录父文档、正文起点、终点和正文总长度。

输入〔问，文〕 → 组织证据〔证〕 → 输出〔答，证，迹〕

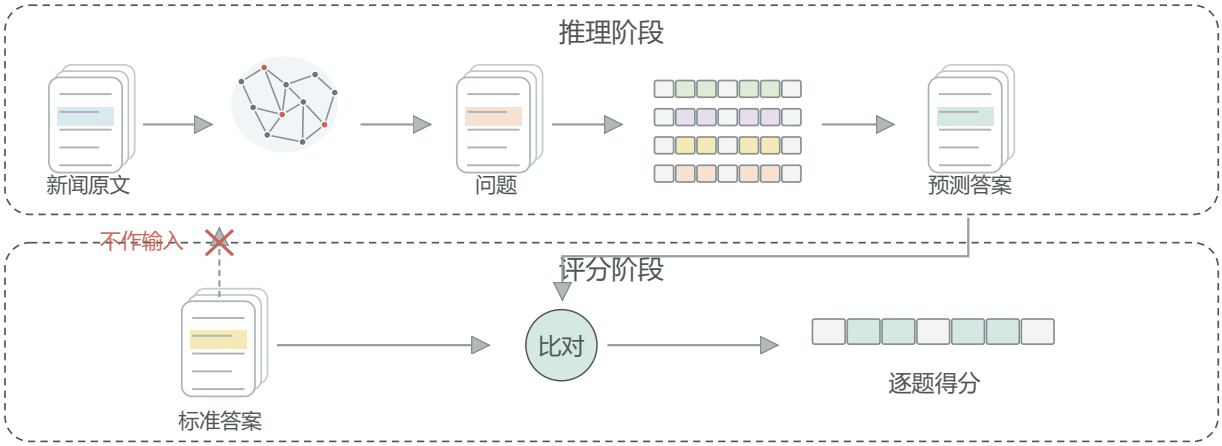


图1 数据角色。上层为推理时可见的原文和问题，下层为预测完成后的标准答案比对；标准答案不进入上层推理。

成功判据

有效作答＝答案非空 ∧ 生成格式有效 ∧ 审查支持 ∧ 引用可定位

效果达标＝完全匹配题数 ÷ 留出题数 ≥ 80%

“未知”表示现有证据不足以决定命题真假，不等同于“假”。无答案题以正确拒答计分，格式无效输出计零；具体评分和逻辑规则见附录甲。

四 方法设计

整个方法分为证据汇聚、父文档重组和事实组合三段。前两段决定哪些内容真正进入推理，后一段决定怎样从这些内容得到题目所问的结论。

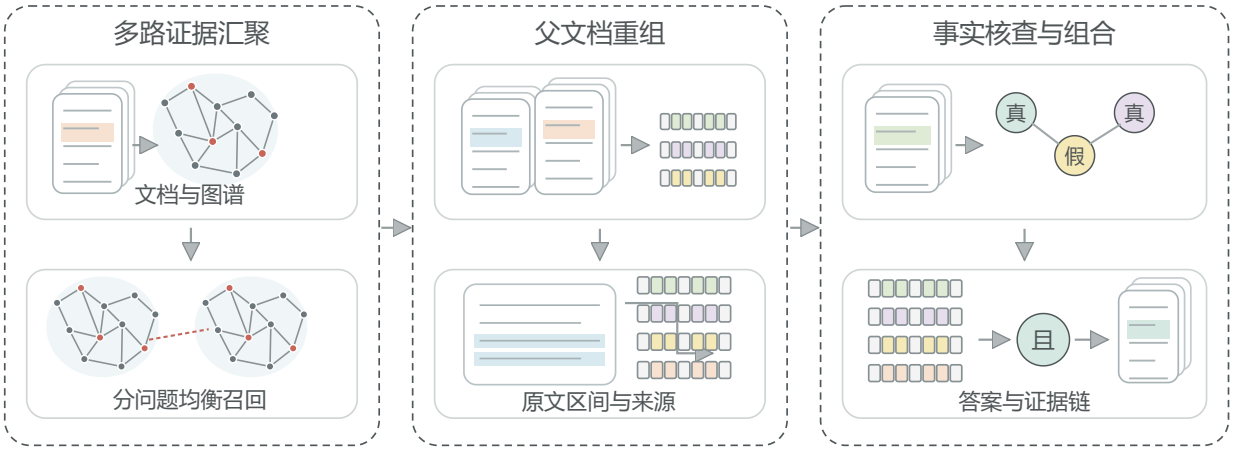


图2 方法总览。左侧汇聚不同检索路径，中部展开并合并原文区间，右侧核查事实并组合答案；节点、文档和向量条为结构示意。

从输入到输出

输入。 自然语言问题与既有新闻知识库。**处理。** 分解问题、多路召回、重排窗口、展开父文档、生成候选、核验事实及按需修复。**输出。** 短答案、原文引用、逻辑判断和执行轨迹。

证据组织器放在生成之前，是因为缺失的来源或时间限定无法由后置核验凭空补回。逻辑组合放在事实核查之后，是为了避免把“题干被反驳”和“否定答案被反驳”混为一谈。修复器只在审查指出具体问题时启动，使额外调用有明确目标。

三段之间传递什么

检索段传递候选父文档；证据段传递带偏移和完整性标记的原文；核验段传递“真、假、未知”等状态以及决定结论的引用。每次传递都保留对应来源，便于在结果页回到原文。

4.1 多路召回与父文档融合

输入。 原问题、最多4个证据需求以及原始文档。**处理。** 分别运行词项概率检索、图谱混合检索和向量检索，在文档层面融合排名，再对局部窗口做相关性重排[10–11]。**输出。** 按证据需求组织的父文档原文区间。

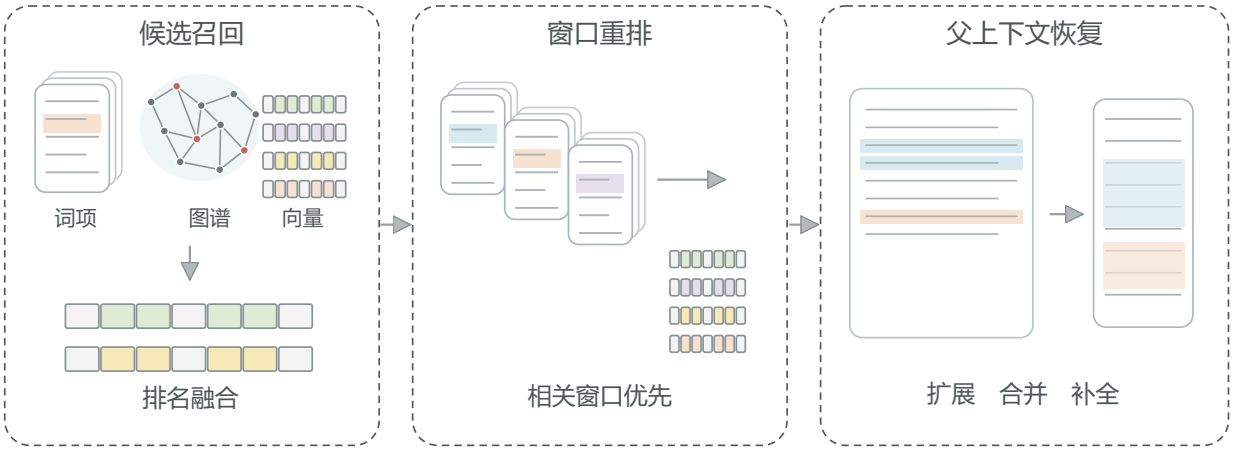


图3 从多路候选到父文档。左侧保留互补命中，中部比较局部窗口，右侧按原文位置扩展、合并，并在预算内补全短文。图中的向量条仅示意排序。

$$\text{融合分数} = \text{各检索路径中}\left(1 \div (60 + \text{文档名次})\right)\text{之和}$$

父文档融合的存在理由很直接：命中句附近往往还有主体、时间或归因信息。若只把句子拿出来，关系可能被读错；若不加选择地增加片段，又可能让重复内容挤占另一个来源。

因此，流程先按子问题保留相关窗口，再根据原文偏移向两侧展开并合并重叠区间。初始上下文不超过64,000字符；正文不超过12,000字符的已选父文档可在余量允许时补全。标题、作者、发布时间与来源同原文一起传递。

最终证据保留父文档编号和起止位置，不依赖每轮临时排序编号。这样，后续核查和修复仍能定位到同一条原文。

4.2 原子事实与三值逻辑

输入。 问题限定的原子命题、原文证据与文档完整性标记。**处理。** 在核验输入中隐藏候选答案，独立判断命题状态，再由程序计算“且、或、非”。**输出。** 确定的肯定或否定结论，以及决定该结论的证据。

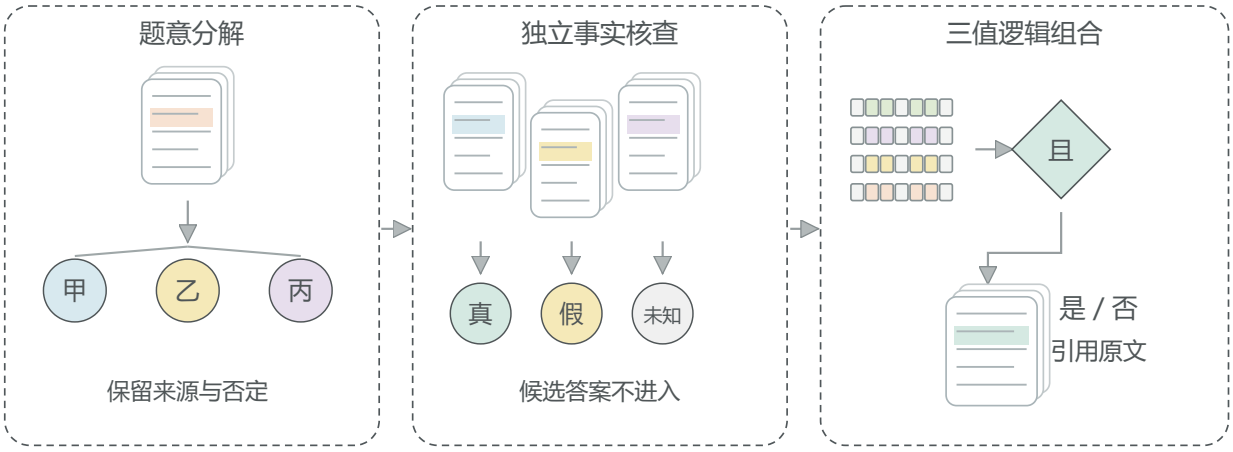


图4 事实判断与答案组合分离。命题先与原文对应，核验结果进入三值逻辑，候选答案只在最后用于对照或纠正。未知状态不会直接转成假。

这一组件专门处理答案极性：如果原文说“输了三场”，它反驳的是“赢了三场”这个命题，因此可以支持题目的否定答案。直接给整段候选打分，容易漏掉这一步转换。

运算	可确定的情况	保留未知的情况
且	任一项为假，则整体为假	没有假，但仍有未知
或	任一项为真，则整体为真	没有真，但仍有未知
非	真与假互换	未知仍为未知

布尔形式最多8个原子命题、32个语法节点。对命名实体类问题，或布尔解析与原子证据尚不能给出结论的问题，联合证据审查可按来源事实直接重建相关证明。完整文档覆盖用于约束显式的“未提及”证明。

4.3 有限预算下的纠错

输入。 候选答案、已选证据和核验意见。**处理。** 支持则返回；缺证据则按缺失需求补检索；候选被反驳则携带审查反馈重新生成。**输出。** 修复后的答案，或保留原因的拒答。

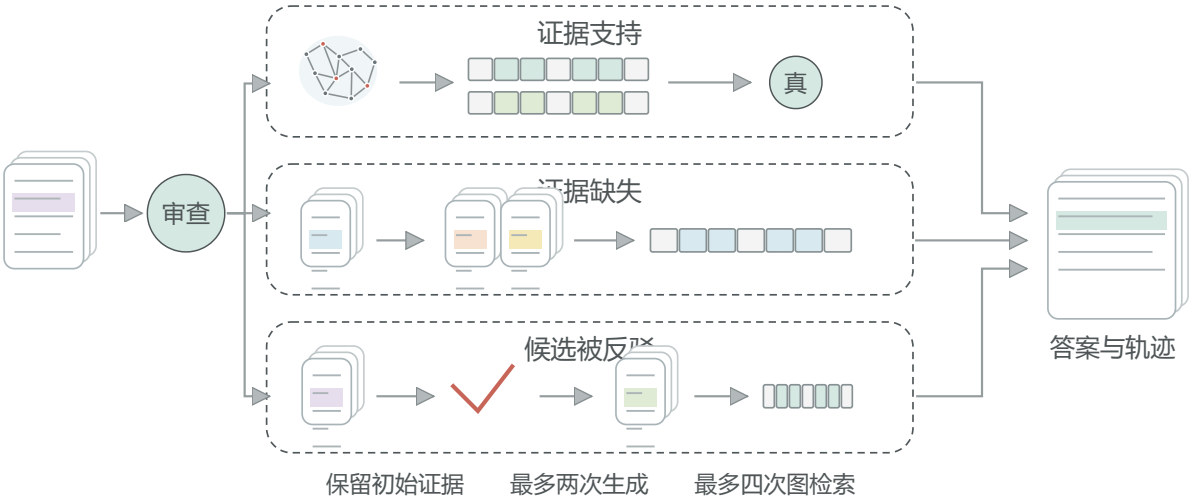


图5 审查结果驱动不同动作。三条支路分别对应直接支持、缺失事实与候选反驳，最终保留答案及完整轨迹；补证不删除首轮证据。

修复器放在审查之后，是为了让新增查询指向真正缺少的事实，而不是反复用同一问题扩大候选数。桥接实体只有在原文里出现过，才可加入补充查询。

整个流程最多补2条查询、生成2次、核验2轮，图检索总数不超过4次；最终证据不超过96,000字符和32段。若合并后没有新增内容，不因重复片段再生成一次。

五 实验设置

5.1 数据集与证据角色

实验使用跨文档多跳问答数据集[12]。本次知识库含609篇英语新闻，处理后得到1,650个文本块、28,423个实体节点和43,733条关系边。原始新闻及其元数据用于检索，问题用于触发推理，标准答案与参考证据用于事后评分。

数据部分	规模	用途
新闻语料	609篇	建立图谱、向量与父文档索引
开发集	24题	定位错误并筛选四轮实现
独立验证集	40题	检查已选方案
新留出测试集	100题	冻结后的最终比较

前瞻证据与事后证据分离

前瞻使用。 题目划分与预算在测试前固定；推理只接收问题、新闻原文、文档元数据和此前产生的审查意见。**事后使用。** 标准答案、参考事实和逐题得分在预测生成后参与评分与误差分析，不回流为该轮输入。图1给出了两种角色的分流。

新测试集从既有测试划分中抽取，排除已使用的200道测试题。与旧测试、开发及验证题的规范化题面完全重复数为0。每题保留全部五个流程的记录，不因失败替换样本。

对照组织

五组分别是基础方案、上一轮补检索、改进候选、改进验证和完整流程。后三组共享首轮候选与初始证据，因此“加验证”和“再修复”的变化可以逐题比较；基础与补检索方案也在同一批新题上重跑。

5.2 运行参数与对照方案

语言模型采用深度求索的闪速接口模型，本地使用智源多语种嵌入与重排序模型。程序运行在单张4090显卡服务器上，图谱、向量与父文档索引保留在本地。原始依赖清单、模型修订标识和冻结材料见附录乙。

环节	固定设置
生成	温度为0，单次超时90秒
问题分解	最多4个证据需求
排名融合	倒数排名常数60
窗口与步长	1,100字符与850字符
重排	每查询32个候选，批量8，最长512词元
父文档补全	正文不超过12,000字符
上下文预算	初始64,000字符，最终96,000字符
纠错预算	2次生成、2轮核验、至多4次图检索

五组流程的可比关系

基础和补检索流程沿用原生成器；三个改进流程使用相同的结构化生成器。候选流程相对基础方案的变化包括检索、上下文与生成提示，验证流程相对候选流程只新增事实核验及逻辑纠正，完整流程再允许一次有目标的修复。

可复现执行

每个阶段保存题目索引、源码哈希和参数。精确输入缓存让配对分支复用同一候选与原始响应；逐题记录同时保存答案、引用和尝试次数。缓存服务于比较一致性，运行时间另以真实资源记录展示。

104项工程测试覆盖来源编号、逻辑状态与执行预算，25项真实接口控制用例覆盖否定、错误年份、无关实体和证据缺失。它们与问答测试分开保存。

5.3 开发筛选与冻结流程

四轮调试回答的是：严格核查是否足够，还是需要互补的证据路径？开发始终使用同一组24题，失败轮次也保留。

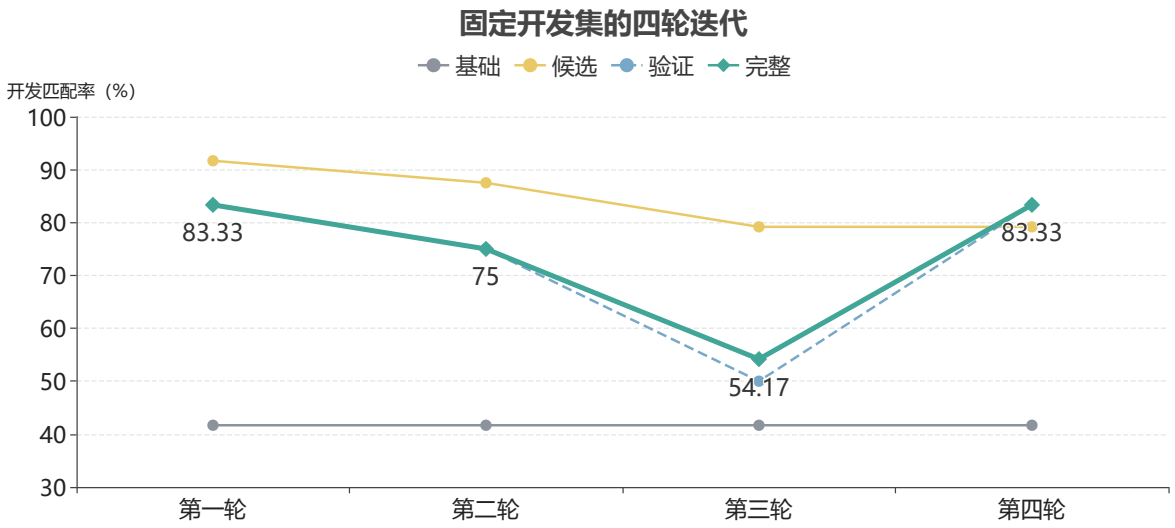


图6 固定24题开发集上的四轮变化。灰线为基础方案，黄线为改进候选，蓝线为验证流程，绿线为完整流程；各轮使用相同题目。

轮次	主要变化	候选匹配率	完整匹配率
一	事实与关系审查	91.67%	83.33%
二	否定措辞、作者信息及格式约束	87.50%	75.00%
三	严格原子命题与布尔核查	79.17%	54.17%
四	互补证明及解析失败保留分解	79.17%	83.33%

第三轮的下降表明，题干解析和原子事实过于细碎时，未知状态会放大误拒。第四轮保留逻辑纠正，并允许来源明确的联合证明补充判断，完整流程回到83.33%。随后确定实现、完成40题验证、冻结源码，再运行100题留出测试。开发分数仅用于筛选，后文只把冻结后的留出结果作为主结论。

六 实验结果

6.1 整体性能

重组证据并加入显式推理后，同一批题能多答对多少？我们同时看全量完全匹配率和可回答题匹配率，避免只用拒答结果判断效果。

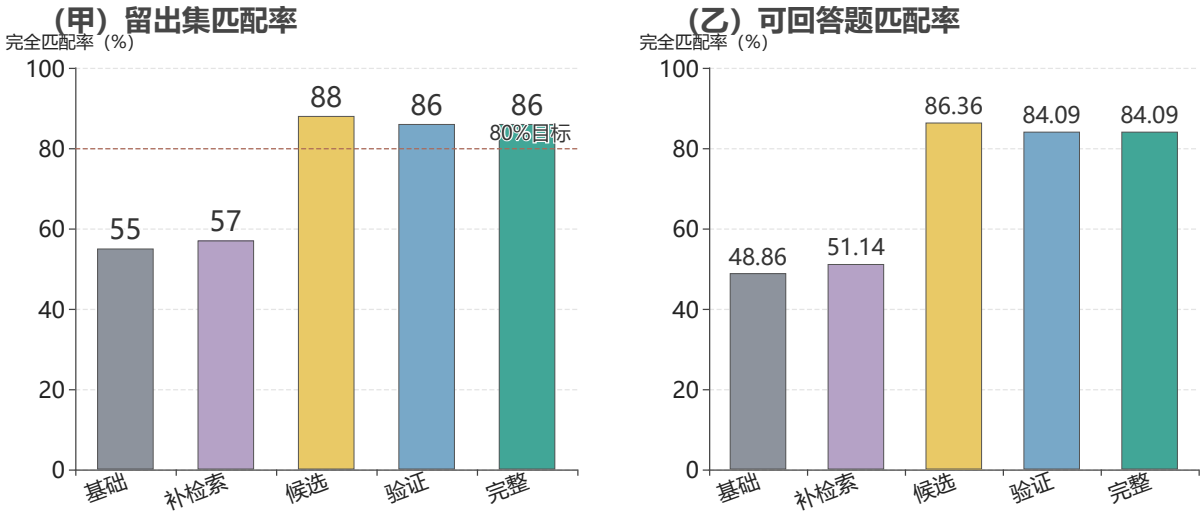


图7 新留出100题的整体表现。甲图为全量完全匹配率，乙图仅统计88道可回答题；甲图虚线为80%目标，五种流程均在同一批题目上运行。

方案	完全匹配率	词元重合分数	可回答题匹配率
基础方案	55.00%	55.74%	48.86%
补检索方案	57.00%	57.74%	51.14%
改进候选流程	88.00%	88.80%	86.36%
改进验证流程	86.00%	86.80%	84.09%
完整流程	86.00%	86.80%	84.09%

完整流程达到86.00%，基础方案为55.00%，净提升31个百分点；同题配对中新增答对33题、丢失2题。可回答题匹配率为84.09%，词元重合分数为86.80%；独立验证集为87.50%，完整表见附录乙。

这些结果支持证据组织与结构化推理的整体改进。由于候选流程也更换了生成提示，31个百分点不能单独归给重排序或验证器；后两者的作用需看消融比较。

6.2 分题型表现

提升是否落在真正需要跨来源组合的问题上？我们将100题拆成比较、推断、时间和无答案四类，观察同题对照的变化。

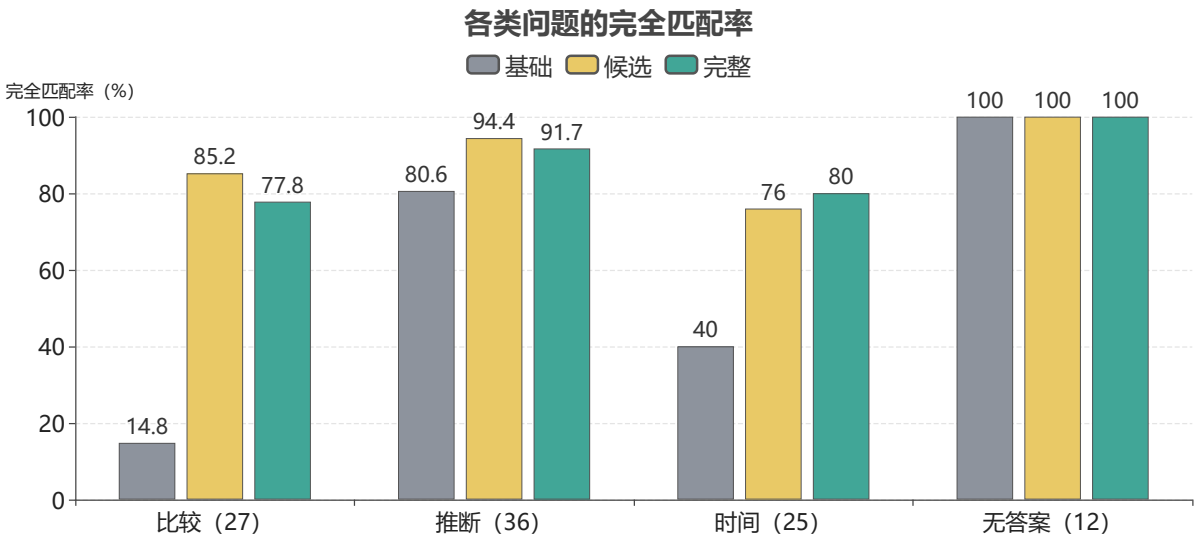


图8 四类问题的完全匹配率，括号内为各类题数。灰、黄、绿三组柱分别对应基础方案、改进候选和完整流程。

题型	题数	基础匹配率	完整匹配率	提升百分点
比较	27	14.81%	77.78%	62.96
推断	36	80.56%	91.67%	11.11
时间	25	40.00%	80.00%	40.00
无答案	12	100.00%	100.00%	0.00

比较题由14.81%升至77.78%，提高62.96个百分点；时间题由40.00%升至80.00%。推断题达到91.67%，12道无答案题均正确拒答。最大的改善落在需要保留多篇报道限定条件的题型，与父上下文和按需求选证的设计相吻合。

分题型结果说明整体收益并非平均分摊，但样本数不同，不能据此排出所有题型的稳定难度；这里比较的是同一批问题上的流程变化。

6.3 消融与错误取舍

验证器是在提高整体正确率，还是在减少已经输出的错误？这两个目标需要分开看。我们比较共享候选和初始证据的改进候选流程与验证流程。

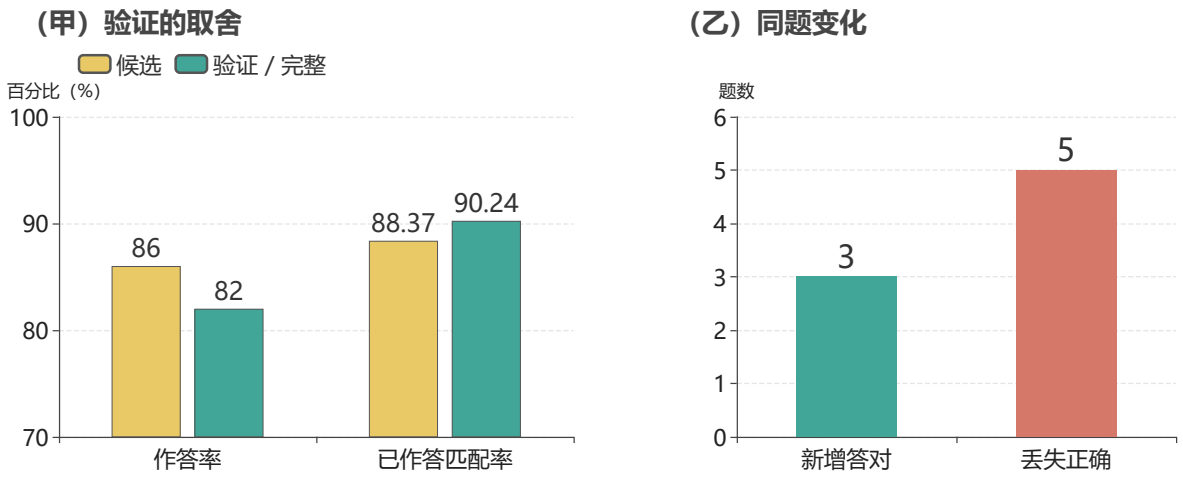


图9 验证的收益与代价。甲图纵轴从70%起，展示作答率与已作答匹配率；乙图为相对候选流程新增答对及丢失正确的题数。

加验证后，全量完全匹配率由88.00%变为86.00%，非空错答由10题减至8题；已作答匹配率由88.37%升至90.24%，作答率由86%降至82%。验证新增答对3题，同时丢失5题；完整流程额外补证后，净分数仍为86.00%。

因此，验证器本轮主要换来了错误抑制与可核查轨迹，而没有净提高匹配率。整体提升首先来自前端证据组织及生成的组合升级，后续应围绕来源限定和否定判断减少误拒，而不是继续一味收紧审查。

6.4 真实证据链案例

核验器能否纠正一次具体的否定判断？测试题1960询问，两篇体育报道中“卡多索伤后入选”和“卡瓦利尼因伤退出”是否形成题目所说的对应关系。以下是两条证据的中文转述，原文定位见附录乙。

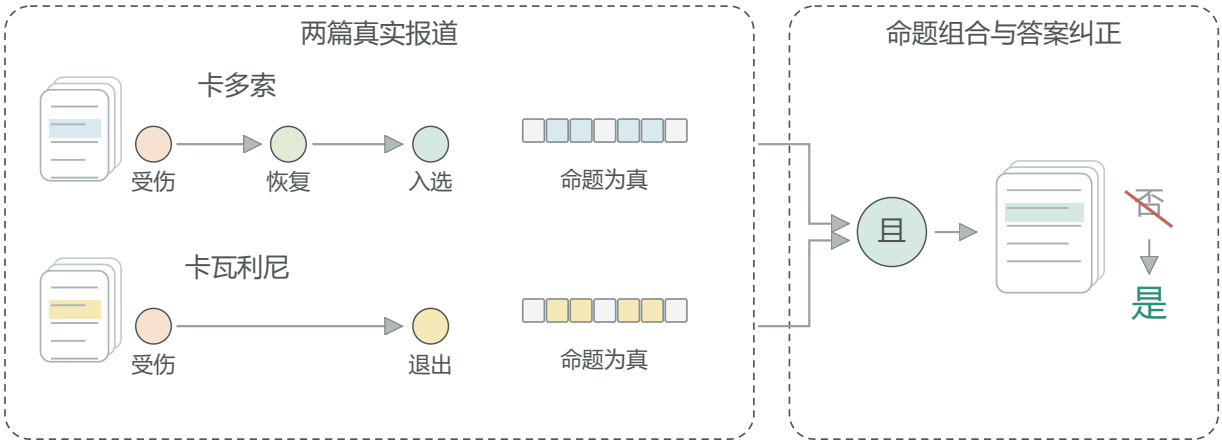


图10 真实题1960的证据组合。卡多索的受伤、恢复和入选来自文档231；卡瓦利尼因伤退出来自文档232；两项核查支持题干，候选“否”被纠正为“是”。

第一条报道写明，卡多索因脚踝伤退出此前集训，恢复俱乐部比赛后入选名单；第二条写明，加拿大队当时唯一的伤病缺席是卡瓦利尼，他在两场比赛前退出。首轮候选为“否”，原子核查重建两项来源事实后，最终答案为“是”，与标准答案一致。

这个样例展示的是独立重建证据如何纠正候选，而不是看到否定答案就将其放行。全测试中共有6次候选极性纠正，其中3次符合标准答案，因此仍要用完整消融结果评价该机制。

七 工程实现与资源

7.1 模块协同与结果留存

服务器只承担本地嵌入、重排和知识计算，语言生成与事实检查通过深度求索接口完成。检索期间不接入外部网页搜索，所有引用都映射到固定语料中的原文。

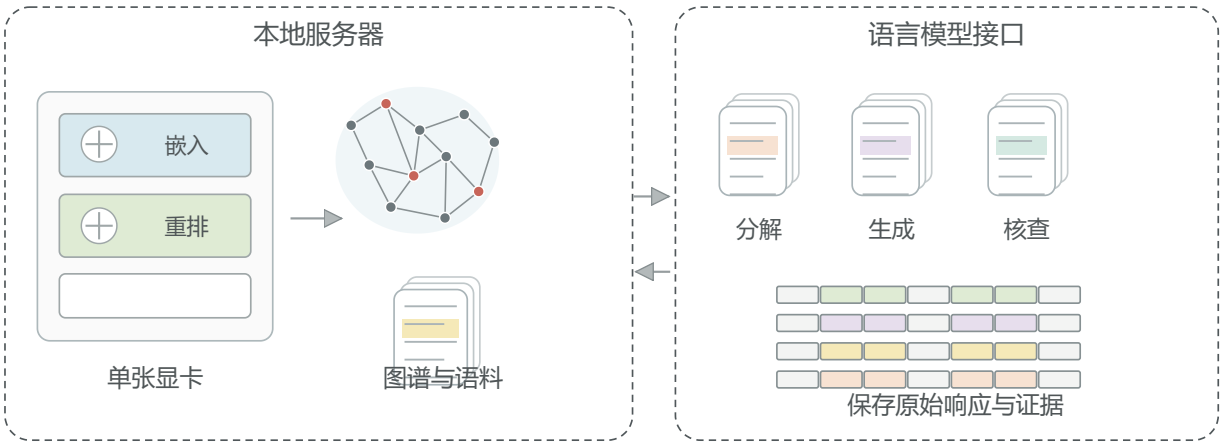


图11 本地计算与模型接口的协同。左侧显卡与语料承担嵌入、重排和图谱计算，右侧完成分解、生成与核查，原始响应和证据轨迹分别留存。

程序按父文档组织器、事实核验器、逻辑组合器、纠错控制器和实验驱动器拆分。模块之间传递带来源的结构化记录，避免每次查询临时重编号；最终答案可以沿着引用、正文偏移和审查结果回溯。

测试与复核

104项工程测试已通过，覆盖来源编号、逻辑组合、完整性判断和预算；25项真实模型接口控制用例全部通过。实验阶段共保存700条独立验证及测试记录，连同开发集共复算1,180条完全匹配率与词元重合分数。

交付保留完整源码、失败轮次、精确输入缓存和每个文件的哈希。原始实验材料与报告图表分开保存，修改展示文字不会改变已冻结的成绩。

7.2 显存与运行记录

单卡方案的本地负担有多大？我们在验证和测试阶段约每秒记录一次显存与计算利用率，用连续采样观察模型加载、检索计算和接口等待期间的资源变化。

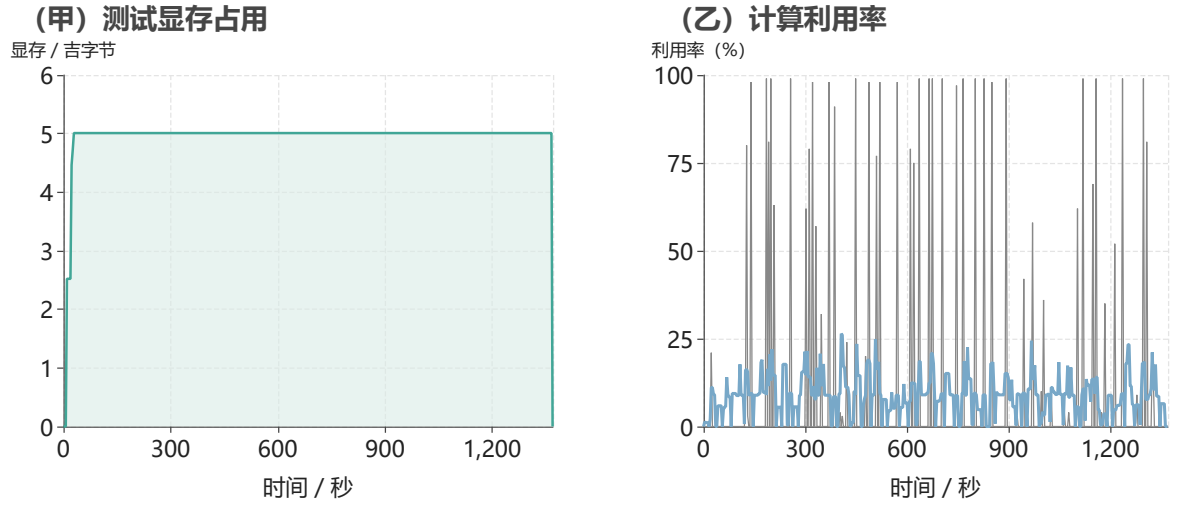


图12　真实测试阶段的显存与利用率。甲图单位为二进制吉字节，乙图灰线为采样值、蓝线为局部均值；时间轴单位为秒。

指标	验证阶段	测试阶段
显卡	4090显卡	4090显卡
采样次数	546	1,268
显存峰值 / 兆字节	5,245	5,129
计算利用率峰值	99%	100%
本地生成模型	不运行	不运行

验证与测试的显存采样峰值为5,245兆字节，约5.12吉字节，单位均为二进制。全部开发、控制检查及主实验共记录1,386条模型响应，累计6,225,251词元。测试结束后显存已释放。

这些记录覆盖本轮验证和测试，不含首次图谱入库。共享缓存用于同题配对，所以图中资源曲线可以说明实际运行负担，但不用于宣称各分支的独立速度差异。

八　结论

多跳问答的改进需要把相关材料组织成能共同支持结论的证据链。本文通过父文档融合、事实与答案组合分离及有限预算修复，把原文获取、上下文恢复和逻辑判断接成可追踪的流程。真实模型实验表明，这一组合显著改善了同题整体表现，尤其是跨来源比较与时间关系问题。下一步将在新的留出样本上校准来源限定和非提及判断，重点减少验证器对正确候选的损失。

应用定位

该方法适合需要回看依据的新闻研究、企业资料核对和知识助手。使用者不仅获得简短答案，也能看到支撑答案的原文区间与组合过程，便于判断哪些事实已经找到、哪些仍需补充。

结论适用范围

- 本文分数对应固定新闻语料和新100题留出集；其他领域应使用新的问题划分验证。
- 程序负责给定事实状态下的逻辑组合，题干解析与原子事实状态仍由模型判断。

数据与使用责任

语料采用公开数据集，报告不包含服务器口令或模型密钥。系统提供答案与证据供人核查，不承诺脱离人工审核的自主决策部署。

团队

河南大学　观微算法队
韩昌达　张中瑜　李嘉栋

参考文献

[1] 开放域问答中的稠密段落检索
研究论文，2020年 原文链接

[2] 面向知识密集任务的检索增强生成
研究论文，2020年 原文链接

[3] 结合段落检索与生成模型的开放域问答
研究论文，2020年 原文链接

[4] 简洁高效的检索增强生成
轻量图谱检索研究，2024年 原文链接

[5] 从局部到全局的图谱增强查询摘要
研究论文，2024年 原文链接

[6] 检索与思维链交替进行的多步问答
研究论文，2023年 原文链接

[7] 纠错式检索增强生成
研究论文，2024年 原文链接

[8] 验证链减少语言模型幻觉
研究论文，2023年 原文链接

[9] 通过自我反思学习检索生成与批判
研究论文，2023年 原文链接

[10] 智源多语种重排序模型
官方模型说明 原文链接

[11] 倒数排名融合检索器
开源实现 原文链接

[12] 跨文档多跳问答数据集
数据集与评估项目，2024年 原文链接

[13] 本项目算法仓库
竞赛工程实现 原文链接

附录甲　评估定义与逻辑规则

一　评分口径

完全匹配率：按既有归一化规则比较预测与标准答案，完全匹配记1，否则记0。词元重合分数：按重合词元计算精确率与召回率的调和均值。无答案题的标准答案为空，格式无效输出一律计零。

词元重合分数＝2×精确率×召回率÷（精确率＋召回率）

作答率为输出非空答案的比例；已作答匹配率仅在作答题上计算；可回答题匹配率仅在非空标准答案题上计算。报告中的肯定与否定答案统一写成“是 / 否”，对应日志中的原始答案标签。

二　三值组合为何成立

对合取关系，只要有一项确定为假，整体即为假；其余项不会改变该结论。对析取关系，只要有一项为真，整体即为真。若没有决定性项而仍存在未知，则结果保持未知。程序保存造成决定性结论的命题集合，形成证据证书。

这保证了已给定原子状态之间的组合一致性。完整父文档判断通过合并正文区间完成：覆盖从0到正文总长度且不存在间隙时，才标记为完整。

三　补充统计

完整流程完全匹配率的威尔逊95%区间为77.86%至91.47%；相对基础流程的配对自助法差值区间为增加21至41个百分点。精确配对检验的双侧概率约为0.0000000367，统计对象为本次100题。

四　样本与失败保留

开发共480条方案记录、独立验证200条、测试500条，合计1,180条。原基础测试流程有4条生成格式错误，完整流程为0条；全部按统一口径保留，不替换题目。

附录乙 复现材料与验证结果

一 原始材料

材料	可核查内容
实验协议与冻结文件	题目索引、预算、源码哈希及冻结时间
逐题结果	答案、候选、原文、偏移和评分
模型响应缓存	精确输入与原始输出
依赖与模型记录	运行环境、模型修订和参数
失败轮次源码	四轮开发的实现与对应结果

运行环境采用解释器3.12.3、张量计算框架2.7.0、图检索库1.5.7、句向量库5.7.0。开发、验证与测试抽样种子分别为2026101511、2026101512和2026101513；补丁、模型标识及完整依赖写在原始交付材料内。

案例1960的两项来源分别定位到文档231的正文0至6374字符，以及文档232的正文9950至13373字符。报告作中文转述，原始英文和核查响应在逐题材料中保留。

二 独立验证集尾表

流程	完全匹配率	作答率	已作答匹配率
基础方案	57.50%	42.50%	88.24%
补检索方案	65.00%	50.00%	90.00%
改进候选流程	90.00%	75.00%	93.33%
改进验证流程	87.50%	75.00%	90.00%
完整流程	87.50%	75.00%	90.00%

验证集共40题，其中32题可回答。完整流程答对35题，作答30题，非空错答3题。该表对应测试前已完成的独立验证，不与主测试题目混合计分。